

BOCETO DE TRABAJO DE FIN DE GRADO

Sistema de Generación Aumentada por Recuperación (RAG) para Automatización de Consultas FAQ en la Gestión de Voluntarios

Autor:	Vicente Rivas Monferrer
Grado:	Ingeniería Informática
Universidad:	Universitat Politècnica de València
Fecha:	Octubre 2025
Versión:	1.0 (Boceto Inicial)

ÍNDICE

- 1. Definición del Problema y Objetivos
- 2. Diseño de Interacción y Experiencia de Usuario
- 3. Programación Multimedia e Integración Tecnológica
- 4. Metodología y Desarrollo del Proyecto
- 5. Validación, Pruebas y Análisis de Resultados
- 6. Innovación y Creatividad
- 7. Impacto Social, Ético y Ambiental
- 8. Documentación Técnica
- 9. Cronograma y Planificación
- 10. Bibliografía y Referencias

1. DEFINICIÓN DEL PROBLEMA Y OBJETIVOS

1.1. Contexto del Problema

La asociación **Damos Nuestra Ilusión (DNI)** de la Universitat Politècnica de València gestiona múltiples actividades de voluntariado que incluyen Desayunos Solidarios (distribución de alimentos a personas sin hogar), COLES (refuerzo escolar), RESIS (residencias de mayores), y actividades generales de gestión.

Los coordinadores y voluntarios enfrentan diariamente **consultas repetitivas** sobre horarios, ubicaciones, procesos de inscripción, duración de eventos y requisitos. Esto genera:

- Saturación del staff: Responder manualmente consume tiempo valioso
- Información fragmentada: Datos dispersos en diferentes documentos
- Latencia en respuestas: Voluntarios esperan horas o días por información básica
- Inconsistencias: Respuestas varían según quién responda
- Barrera de entrada: Nuevos voluntarios se desmotivan por falta de información inmediata

1.2. Motivación del Proyecto

Los sistemas tradicionales de FAQ estáticos no contextualizan respuestas, requieren palabras clave exactas, no son escalables y tienen baja satisfacción de usuario. Los **Modelos de Lenguaje de Gran Escala (LLMs)** ofrecen una alternativa, pero sufren de alucinaciones, desactualización y costos elevados en APIs comerciales.

La arquitectura **RAG (Retrieval-Augmented Generation)** combina recuperación de información real con generación de respuestas naturales, ofreciendo:

- Recuperación: Busca información relevante en documentación real
- Generación: Utiliza LLMs para crear respuestas naturales y contextualizadas
- Verificabilidad: Cita fuentes específicas para cada respuesta
- Actualización: Basta con modificar documentos, no reentrenar modelos

1.3. Objetivos del Proyecto

Objetivo General

Desarrollar un **sistema RAG optimizado** que automatice la respuesta a consultas FAQ en la gestión de voluntarios de DNI, garantizando respuestas precisas, contextualizadas y verificables.

Objetivos Específicos

OE1. Diseño e Implementación del Sistema RAG: Implementar arquitectura RAG modular con retrieval híbrido (semántico + BM25) e integrar múltiples modelos LLM del servidor Ollama UPV.

OE2. Optimización del Rendimiento: Implementar optimización bayesiana de hiperparámetros RAG, comparar rendimiento de 4 modelos LLM distintos y reducir tiempos de respuesta.

OE3. Sistema de Evaluación Robusto: Implementar métricas RAGAs (Faithfulness, Context Precision, Answer Relevancy, etc.) y desarrollar métricas personalizadas adaptadas al dominio de voluntariado.

OE4. Interfaz de Usuario y Visualización: Desarrollar dashboard interactivo con Streamlit para análisis cualitativo/cuantitativo e implementar exportación profesional (Excel, PDF, Markdown).

OE5. Validación Experimental: Comparar rendimiento de 4 modelos LLM en 26 preguntas reales, analizar evolución del sistema a través de 3 versiones (v1.0 → v2.1) y documentar problemas críticos.

2. DISEÑO DE INTERACCIÓN Y EXPERIENCIA DE USUARIO

2.1. Perfiles de Usuario

Coordinador de Actividades:

Responder consultas rápidamente sin perder tiempo. Conocimiento técnico bajo-medio. Espera respuestas precisas con citas verificables. Uso diario.

Voluntario Nuevo:

Información clara sobre cómo participar. Conocimiento técnico bajo. Espera lenguaje sencillo sin jerga técnica. Uso puntual (fase de incorporación).

Investigador/Evaluador:

Métricas detalladas de rendimiento. Conocimiento técnico alto. Espera dashboard técnico con análisis profundo. Uso semanal (evaluación de mejoras).

2.2. Principios de Diseño Aplicados

- Simplicidad: Interfaz minimalista sin sobrecargas visuales
- Transparencia: Mostrar fuentes y grado de confianza en respuestas
- Accesibilidad: Diseño responsive para móviles y desktop
- Eficiencia: Tiempos de respuesta < 15 segundos
- Profesionalidad: Estilo consistente tipo plataforma educativa (Moodle)

3. PROGRAMACIÓN MULTIMEDIA E INTEGRACIÓN TECNOLÓGICA

3.1. Stack Tecnológico

Componente	Tecnología	Versión
Lenguaje	Python	3.12+
Framework RAG	LangChain	0.1.0
Vector Store	ChromaDB	0.4.22
Embeddings	sentence-transformers	2.3.1
Evaluación	RAGAs	0.1.7
Frontend	Streamlit	1.31.0
Visualización	Plotly	5.18.0
Exportación	openpyxl, reportlab	3.1.2, 4.0.9

3.2. Modelos LLM Evaluados

Modelo	Parámetros	Proveedor	Context Window
gemma2:27b	27B	Google	2048 tokens
llama3.3:70b	70B	Meta	4096 tokens
qwen3:32b	32B	Alibaba	2048 tokens
deepseek-r1	Variable	DeepSeek	2048 tokens

Nota: Todos los modelos se ejecutan en el servidor Ollama GTI-IA de la UPV, sin necesidad de API keys comerciales.

4. METODOLOGÍA Y DESARROLLO DEL PROYECTO

4.1. Enfoque de Desarrollo

Se adoptó una metodología de **desarrollo iterativo incremental** con evaluación continua. El proyecto se desarrolló en 6 días intensivos (07-12 de octubre de 2025), generando 15 commits distribuidos en 5 fases principales.

4.2. Evolución del Sistema

Versión	Fecha	Score	Mejora	Característica Principal
v1.0	07/10	0.770	-	RAG básico + FAISS
v1.5	08/10	0.820	+6.5%	Hybrid Retrieval + FAQ Chunking
v2.0	10/10	0.855	+4.3%	10 mejoras avanzadas RAG
v2.1	11/10	0.855	±0%	Estabilización + Dashboard v3

Mejora total: +11.0% de score en 5 días de desarrollo intensivo.

5. VALIDACIÓN, PRUEBAS Y ANÁLISIS DE RESULTADOS

5.1. Dataset de Evaluación

Se construyó un dataset de **26 preguntas** representativas, distribuidas en 4 categorías:

- DESAYUNOS: 9 preguntas (34.6%) - Eventos de desayunos y cenas solidarias
- COLES: 10 preguntas (38.5%) - Refuerzo escolar y actividades con niños
- RESIS: 4 preguntas (15.4%) - Residencias y actividades con personas mayores
- GENERAL: 3 preguntas (11.5%) - Información administrativa y filosófica de DNI

5.2. Métricas RAGAs Implementadas

- **Faithfulness:** Fidelidad de la respuesta al contexto recuperado (evita alucinaciones)
- **Answer Relevancy:** Relevancia de la respuesta para la pregunta original
- **Context Precision:** Proporción de chunks relevantes entre los recuperados
- **Context Recall:** Cobertura del contexto vs información necesaria
- **Answer Correctness:** Corrección factual comparada con respuesta esperada
- **Answer Similarity:** Similitud semántica con ground truth

5.3. Resultados Comparativos de Modelos

Modelo	Score	Correctas	Incompletas	Incorrectas	Tiempo (s)
gemma2:27b	0.855	22/26 (84.6%)	3/26 (11.5%)	1/26 (3.8%)	8.5
qwen3:32b	0.834	17/26 (65.4%)	6/26 (23.1%)	3/26 (11.5%)	12.3
llama3.3:70b	0.824	20/26 (76.9%)	4/26 (15.4%)	2/26 (7.7%)	18.7
deepseek-r1	0.617	10/26 (38.5%)	8/26 (30.8%)	8/26 (30.8%)	10.2

Conclusión: gemma2:27b es el mejor modelo individual con el mejor balance score/tiempo y mayor consistencia (84.6% de preguntas correctas).

6. INNOVACIÓN Y CREATIVIDAD

6.1. Aspectos Innovadores del Proyecto

Arquitectura RAG Híbrida Optimizada:

Combinación de retrieval semántico (ChromaDB) + keyword (BM25) con pesos optimizados empíricamente (60% semantic, 40% keyword). Mejora de +6.5% sobre retrieval semántico puro.

Sistema de Evaluación sin API Keys Comerciales:

RAGAs funcionando completamente con Ollama local (sin OpenAI/Anthropic). Coste \$0 vs ~\$50-100 por benchmark con GPT-4. Privacidad total: datos nunca salen de infraestructura UPV.

Dashboard de Análisis Cualitativo Automático:

Evaluación automática Correcta/Incompleta/Incorrecta mediante heurísticas inteligentes. Reduce evaluación manual de ~4 horas a 5 minutos.

Query Expansion con Sinónimos de Dominio:

Diccionario específico de términos DNI UPV ('resis' → 'residencias', 'coles' → 'refuerzo escolar'). Mejora retrieval en +15% para preguntas con jerga específica.

FAQ-Aware Chunking:

Chunking que preserva pares pregunta-respuesta juntos, evitando cortar Q&A; por la mitad. Mejora de +3% en preguntas tipo FAQ literal.

7. IMPACTO SOCIAL, ÉTICO Y AMBIENTAL

7.1. Impacto Social

Beneficiarios Directos:

- Coordinadores de DNI (~15 personas): Ahorro de ~10 horas/semana respondiendo consultas
- Voluntarios Activos (~200 personas): Acceso inmediato a información, mayor autonomía
- Voluntarios Potenciales (~1000 contactos/año): Reducción de barrera de entrada, onboarding más rápido

Replicabilidad:

El sistema es completamente open-source (licencia MIT), sin dependencias de APIs de pago, y con documentación exhaustiva. Potenciales adoptantes: ~50 asociaciones de voluntariado universitario en España, ONGs con gestión de FAQ intensiva, plataformas de voluntariado nacional.

7.2. Consideraciones Éticas

- ✓ No almacenamiento de PII (información personal identificable)
- ✓ Procesamiento local en Ollama UPV (infraestructura europea, GDPR-compliant)
- ✓ Sin tracking de usuarios en el dashboard
- ✓ Datos del benchmark anonimizados (solo preguntas genéricas)
- ✓ Citación de fuentes: Cada respuesta incluye chunks recuperados con scores
- ✓ Transparencia: Sistema indica claramente cuando no tiene información

7.3. Impacto Ambiental

Huella de carbono estimada: ~30 kg CO₂e/año (inferencia en servidor compartido). **Balance neto:** -18 kg CO₂e/año (positivo), ya que se ahorran ~48 kg CO₂e/año por emails evitados (1000 consultas/mes × 4g CO₂e/email).

8. DOCUMENTACIÓN TÉCNICA

8.1. Requisitos del Sistema

- **Hardware:** CPU 4 cores, RAM 8GB mínimo (16GB recomendado), 10GB almacenamiento
- **Software:** Python 3.12+, pip 22.0+, git 2.30+
- **Red:** Conexión estable a servidor Ollama UPV

8.2. Instalación Rápida

```
# 1. Clonar repositorio git clone https://github.com/vicenteR/rag_optimizer.git cd rag_optimizer # 2. Crear entorno virtual python3.12 -m venv venv source venv/bin/activate # 3. Instalar dependencias pip install -r requirements.txt # 4. Crear vector store python scripts/01_create_vector_store_chroma.py # 5. Lanzar dashboard streamlit run app_v3.py
```

9. CRONOGRAMA Y PLANIFICACIÓN

9.1. Cronograma Real del Desarrollo (Octubre 2025)

Día	Fecha	Fase	Horas	Commits
1	07/10	Investigación + Prototipo v1.0	12h	5
2	08/10	Optimización inicial	10h	3
3	09/10	Crisis técnica + Solución	6h	1
4	10/10	RAG v2.0 completo	12h	4
5	11/10	Consolidación v2.1	8h	2
6	12/10	Documentación exhaustiva	6h	1
		TOTAL	54h	16

9.2. Cronograma Propuesto para TFG Completo (4 Meses)

Mes	Fase	Entregables
1	Estado del Arte + Diseño	Cap. 2 (Marco Teórico) + Cap. 3 (Análisis y Diseño)
2	Implementación + Optimización	Código funcional v1.0 + v2.0
3	Evaluación + Dashboard	Cap. 5 (Validación) + Dashboard v3
4	Documentación + Defensa	Memoria TFG + Presentación

10. BIBLIOGRAFÍA Y REFERENCIAS

10.1. Referencias Académicas Principales

- [1] Lewis, P., et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Proceedings of NeurIPS 2020.
- [2] Guu, K., et al. (2020). *REALM: Retrieval-Augmented Language Model Pre-Training*. Proceedings of ICML 2020.
- [3] Es, S., et al. (2023). *RAGAs: Automated Evaluation of Retrieval Augmented Generation*. arXiv preprint.
- [4] Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. Proceedings of EMNLP 2019.
- [5] Touvron, H., et al. (2023). *Llama 2: Open Foundation and Fine-Tuned Chat Models*. arXiv preprint.
- [6] Team, G., et al. (2024). *Gemma 2: Improving Open Language Models at a Practical Size*. arXiv preprint.
- [7] Bai, J., et al. (2023). *Qwen Technical Report*. arXiv preprint.

10.2. Frameworks y Herramientas

- [8] LangChain Documentation. <https://python.langchain.com/>
- [9] ChromaDB Documentation. <https://docs.trychroma.com/>
- [10] RAGAs Framework. <https://docs.ragas.io/>
- [11] Streamlit Documentation. <https://docs.streamlit.io/>
- [12] Ollama Documentation. <https://ollama.ai/>

FIN DEL BOCETO DEL TFG

Este documento es un boceto inicial sujeto a revisión y ampliación durante el desarrollo del Trabajo de Fin de Grado.

Contacto:

Vicente Rivas Monferrer
vicente.rivas@upv.edu.es
Universitat Politècnica de València
Grado en Ingeniería Informática

Fecha de elaboración: 16 de Octubre de 2025

Versión del documento: 1.0 (Boceto Inicial)